

C.E.S.A.R - Centro de Estudos e Sistemas Avançados do Recife
CIÊNCIA DA COMPUTAÇÃO

RELATÓRIO DE ANÁLISE
600 Billboard Hot 100 Tracks (with Spotify Data)

Bruno Ribeiro Lima Lins Araújo
Vinícius Calheiros de Lima Petribu

RECIFE
NOVEMBRO 2024

Introdução

O relatório tem como objetivo explorar estatisticamente os dados musicais de 620 faixas do Billboard Hot 100 entre os anos de 2000 e 2023. Este período representa a evolução de tendências no cenário musical contemporâneo, capturando as dinâmicas do pop e R&B ao longo das duas últimas décadas.

Com base nas ferramentas apresentadas, como estatística descritiva, normalização padrão, análise de distribuições amostrais e cálculo de intervalos de confiança, busca-se compreender as características sonoras e métricas de popularidade que influenciam o sucesso das músicas. O dado Popularidade representa uma pontuação atribuída pelo Spotify para indicar o nível de popularidade de uma música, variando em uma escala de 0 a 100. Essa métrica é calculada com base em fatores como a frequência de reprodução recente, o número de curtidas ou salvamentos pelos usuários, e o engajamento global na plataforma. Quanto maior o valor, maior o interesse atual pela música entre os ouvintes. É uma medida dinâmica que reflete o desempenho relativo de uma faixa em termos de apelo e consumo, sendo particularmente útil para identificar tendências e comparar a recepção de diferentes músicas ao longo do tempo. Dito isso, é a coluna que mais destacamos durante a execução do trabalho.

A análise também abrange métricas detalhadas fornecidas pelo Spotify, como dançabilidade, energia, valência, e tempo. Utilizando técnicas como box plots, histogramas, mapas de calor e distribuições de médias, o relatório oferece insights sobre os atributos que tornam as músicas populares.

Esta abordagem permite explorar tendências na música contemporânea e destacar as conexões entre métricas quantitativas e o apelo artístico das faixas. A justificativa de cada análise será fundamentada em interpretações críticas e referências relevantes, sempre buscando associar os resultados obtidos aos fenômenos culturais e comerciais que moldaram a música neste período.

Colunas


Coluna	Explicação
Track	O título da música
Artists	O nome do artista ou grupo
Album	O álbum no qual a faixa foi lançada
Year	O ano de lançamento da faixa
Duration	A duração da faixa em milissegundos
Time_Signature	A fórmula de compasso musical (ex.: 4/4) da faixa
Danceability	Uma medida de quão apropriada a faixa é para dançar, variando de 0 a 1
Energy	Uma medida da intensidade e atividade da faixa, variando de 0 a 1
Key	A tonalidade em que a faixa foi composta, representada como um inteiro (ex.: C=0, D=2)
Loudness	O volume geral da faixa (em dB)
Mode	Indica a modalidade da faixa (0 para menor, 1 para maior)
Speechiness	Uma medida da presença de palavras faladas na faixa, variando de 0 a 1
Acousticness	Uma medida dos elementos acústicos na faixa, variando de 0 a 1
Instrumentalness	Uma medida da presença de elementos vocais versus instrumentais, variando de 0 a 1
Liveness	Uma medida da probabilidade de que a faixa foi gravada ao vivo, variando de 0 a 1
Valence	Uma medida da positividade musical transmitida pela faixa, variando de 0 a 1

Tempo	A velocidade da faixa em batidas por minuto (BPM)
Popularity	A pontuação de popularidade da faixa, fornecida pelo Spotify, variando de 0 a 100

Estatística Descritiva


Box plots

Duração em milissegundos




- Este box plot exhibe a distribuição da duração das músicas no dataset. A mediana está em aproximadamente 201.936 ms (~3 minutos e 22 segundos), representando a duração típica das músicas populares.
- A caixa (entre o primeiro e o terceiro quartis) mostra que 50% das músicas têm duração entre 178.854 ms (~2 minutos e 59 segundos) e 226.906 ms (~3 minutos e 47 segundos).
- Há outliers acima de 400.000 ms (~6 minutos e 40 segundos) e abaixo de 100.000 ms (~1 minuto e 40 segundos), indicando faixas muito longas ou muito curtas, possivelmente versões especiais ou interlúdios.

Ritmo (BPM)




- O gráfico demonstra a variação do tempo (BPM) das músicas, uma métrica que influencia o ritmo e a energia percebida.
- A mediana de 122 BPM indica que a maioria das músicas segue um ritmo moderado, adequado para dançar e consumir em massa.
- As faixas com tempos abaixo de 70 BPM e acima de 160 BPM são outliers, indicando músicas mais lentas ou aceleradas, respectivamente, características de gêneros específicos como baladas ou eletrônicas de alta energia.

Intensidade (dB)



- Este gráfico analisa a intensidade sonora das músicas em decibéis, uma métrica que afeta a percepção de energia.
- A mediana próxima de -6 dB reflete níveis típicos de masterização para músicas modernas, otimizadas para consumo em plataformas digitais.
- Os outliers abaixo de -14 dB sugerem músicas mais silenciosas ou menos comprimidas, possivelmente faixas acústicas ou com menos processamento.


Energia



- Este gráfico avalia a distribuição da energia das músicas, um atributo que mede intensidade e atividade.
- A mediana próxima de 0,6 mostra que a maioria das músicas possui energia moderada, alinhada com a dinâmica da música pop.
- Outliers abaixo de 0,2 representam músicas de baixa energia, como baladas ou acústicas, enquanto valores acima de 0,8 correspondem a músicas muito intensas, como faixas eletrônicas ou de alta performance.

Popularidade

Box Plot of Popularity



- Este gráfico ilustra a popularidade das músicas, medida em uma escala de 0 a 100. A mediana de 69 indica que muitas faixas analisadas têm alta aceitação pelo público.


- A caixa mostra que 50% das músicas estão entre as pontuações de 60 e 77, sugerindo consistência em popularidade.
- Há outliers abaixo de 35, indicando músicas com menor engajamento, possivelmente devido a estilos de nicho ou falta de promoção.

Conclusão

- Os box plots ajudam a visualizar as características gerais das músicas do dataset, identificando padrões de duração, ritmo, volume, energia e popularidade. Esses insights são úteis para entender o que define um "hit" e explorar variações entre diferentes faixas ou estilos.


Histograma

Popularidade




- Este histograma mostra a distribuição das músicas em relação à popularidade, que é medida em uma escala de 0 a 100.
- Observa-se uma concentração maior na faixa de 60 a 80, com o pico próximo de 69, indicando que a maioria das músicas analisadas têm uma popularidade relativamente alta.
- Há uma queda significativa nos valores abaixo de 40, o que sugere que músicas com baixa popularidade são menos comuns no dataset, provavelmente por serem menos conhecidas ou representarem nichos específicos.

Ano




- Este gráfico exibe a frequência das músicas distribuídas ao longo do tempo, de 2000 a 2023.
- O aumento constante na frequência das músicas ao longo dos anos reflete uma maior representação dos anos recentes no dataset. Isso pode ser explicado pela maior quantidade de músicas lançadas e registradas devido à digitalização e crescimento das plataformas de streaming.
- O pico em 2023 sugere que o dataset é mais completo para os anos recentes, o que é comum em análises de dados contemporâneos.

Liveness




- Este gráfico analisa a "vivacidade" das músicas, que mede a probabilidade de uma faixa ter sido gravada ao vivo.
- A maior parte das músicas tem valores próximos de 0,1, indicando que a maioria das faixas são produzidas em estúdio com pouca interferência de elementos ao vivo.
- Os valores mais altos, acima de 0,4, representam um pequeno número de músicas que possuem características mais "ao vivo".

Energia



- Este histograma mostra a distribuição da energia das músicas, medida em uma escala de 0 a 1, com valores mais altos indicando maior intensidade.
- O pico ocorre em torno de 0,6, indicando que a maioria das músicas possuem energia moderada, o que é típico de faixas pop e comerciais.
- Os valores mais baixos ($<0,2$) representam músicas mais calmas, como baladas, enquanto valores próximos a 1 indicam músicas muito intensas, como eletrônicas ou dançantes.

Duração



Este gráfico apresenta a duração das músicas em milissegundos.

A maioria das faixas está concentrada em torno de 200.000 ms (~3 minutos e 20 segundos), que é o tempo médio esperado para músicas populares.


Há uma leve assimetria à direita, indicando algumas músicas mais longas (>300.000 ms).

Conclusão

- Os histogramas fornecem uma visão clara das características das músicas do dataset, evidenciando padrões esperados para música pop, como popularidade alta, energia moderada, vivacidade baixa, e durações médias entre 3 e 4 minutos. Esses gráficos ajudam a identificar tendências gerais e possíveis exceções, oferecendo insights úteis para análise musical e mercadológica.

Scatter plot

Loudness X Energia




Este scatter plot revela uma relação positiva entre o volume (Loudness) e a energia (Energy) das músicas.

À medida que o volume aumenta (mais próximo de 0 dB), a energia tende a ser maior.

Isso reflete o fato de que músicas mais altas frequentemente transmitem maior intensidade e dinamismo, especialmente em gêneros eletrônicos ou pop dançante.

A forte correlação positiva entre energia e loudness destaca que músicas mais intensas geralmente são masterizadas com maior volume, seguindo as tendências da "guerra do loudness". Segundo TARDI (2020), esse aumento no loudness é frequentemente utilizado para criar um impacto imediato nos ouvintes, especialmente em faixas comerciais destinadas a plataformas de streaming. Isso reforça como a percepção de energia está atrelada ao apelo emocional de músicas populares, alinhando-se com a análise que identificou altos níveis de energia em músicas de sucesso.

Danceability X Popularidade




O gráfico mostra a relação entre a capacidade de dançar uma música (Danceability) e sua popularidade.

Embora não haja uma correlação clara, observa-se que músicas populares (popularidade > 60) têm uma distribuição ampla em danceability, o que sugere que faixas com diferentes níveis de adequação para dança podem ser populares, dependendo de outros fatores como gênero ou contexto.

Segundo estudos da área de musicologia digital, o sucesso de uma música está relacionado a uma combinação de fatores, incluindo marketing, contexto cultural e características sonoras únicas (SERRÀ et al., 2012). No entanto, faixas com alta danceability tendem a ser mais exploradas em gêneros voltados para o entretenimento, como dance e pop eletrônico, alinhando-se às tendências da música mainstream.

Acusticidade X energy




Este gráfico ilustra uma correlação negativa entre os níveis de acústica (Acousticness) e a energia (Energy).

Músicas altamente acústicas ($\text{acousticness} > 0,8$) tendem a ter baixa energia, indicando que faixas com elementos acústicos predominantes, como baladas ou acústicos ao vivo, são menos intensas. Por outro lado, a maioria das músicas no dataset está concentrada em níveis baixos de acústica ($\text{acousticness} < 0,2$) e apresenta valores de energia elevados ($\text{energy} > 0,6$). Isso sugere que músicas com menos características acústicas, como produções eletrônicas e pop moderno, dominam as faixas energéticas do dataset.

A relação inversa entre acousticness e energia reflete a separação entre músicas acústicas e eletrônicas/comerciais. Estudos sugerem que faixas acústicas são frequentemente associadas a contextos mais íntimos e reflexivos, enquanto músicas eletrônicas, com baixa acousticness , priorizam intensidade e dinamismo (BERGERON & WILD, 2016). Isso explica por que músicas de alta energia, como hits pop e dance, apresentam níveis mais baixos de acousticness .

Popularidade X duração




Esse scatter plot analisa a relação entre a duração das músicas (Duration) e sua popularidade. O scatter plot Popularity vs Duration é um dos gráficos mais úteis para identificar padrões claros no dataset, mostrando como a duração das músicas influencia sua popularidade. A maioria das músicas populares (popularidade acima de 60) está concentrada em uma duração que varia entre 2 e 4 minutos, o que reflete uma tendência padrão no mercado musical, especialmente para faixas destinadas ao rádio ou plataformas de streaming.

Apesar de não haver uma relação direta linear, o gráfico destaca que músicas populares geralmente seguem o "tempo padrão" para lançamentos comerciais. Isso é evidenciado pela alta densidade de pontos no intervalo mencionado, demonstrando que a duração é uma variável importante para o sucesso das músicas no mercado atual.


A análise revelou que músicas populares têm duração predominantemente entre dois e quatro minutos. Esse padrão é consistente com o comportamento do mercado musical contemporâneo, que favorece faixas curtas e concisas, otimizadas para plataformas de streaming. Conforme SMITH (2018), a ascensão do streaming redefiniu a duração ideal das músicas, priorizando faixas que prendam rapidamente a atenção do ouvinte.

Dancabilidade X loudness



O scatter plot Danceability vs Loudness apresenta uma análise interessante sobre como o volume percebido (loudness) está relacionado à capacidade de dança (danceability) de uma música. Embora não haja uma relação clara e linear, observa-se que músicas com loudness moderado (entre -8 dB e -4 dB) tendem a cobrir uma ampla faixa de danceability, indicando que esse nível de volume pode ser ideal para músicas voltadas para o público dançante.

Mapa de Calor




A matriz de correlação visualizada através do heatmap oferece insights sobre as relações entre as variáveis do dataset. Os principais destaques incluem:

1. **Energy e Loudness (0.79):** Existe uma forte correlação positiva entre energia e volume percebido, indicando que músicas mais intensas (alta energia) também tendem a ser mais altas em termos de volume. Isso reflete a preferência por produções impactantes em gêneros populares.
2. **Valence e Loudness (0.42):** Há uma correlação moderada positiva entre valência (positividade musical) e volume, sugerindo que músicas mais felizes tendem a ser mais altas.
3. **Acousticness e Energy (-0.61):** Uma correlação negativa considerável entre acústica e energia reafirma que músicas com características acústicas marcantes são geralmente menos intensas.
4. **Danceability e Valence (0.36):** Músicas mais dançantes apresentam uma leve tendência a serem associadas a uma tonalidade mais positiva, o que é típico em músicas destinadas ao entretenimento.
5. **Speechiness e Popularity (-0.23):** Existe uma correlação negativa entre a presença de palavras faladas e a popularidade, indicando que músicas muito faladas, como discursos ou trechos de rap puro, tendem a ser menos populares.
6. **Duration e Year (-0.32):** A correlação negativa entre a duração das músicas e os anos de lançamento sugere que músicas mais curtas se tornaram mais comuns nas últimas décadas, alinhando-se com tendências de consumo acelerado em plataformas digitais.

Conclusão: O heatmap demonstra como características musicais influenciam e interagem entre si, revelando padrões significativos. Variáveis como energia e loudness têm fortes associações positivas, enquanto a acústica é inversamente relacionada à energia, mostrando que a natureza de uma música é definida por um equilíbrio dessas características. Além disso, algumas variáveis apresentam pouca ou nenhuma correlação direta com popularidade, indicando que outros fatores externos, como marketing e tendências, podem ter um papel importante no sucesso de uma música.

Normalização Padrão: Dançabilidade e popularidade



	Danceability	Popularity
0	0.933687	-1.240963
1	0.260147	0.658602
2	0.102510	0.220241
3	-0.341740	0.585542
4	-0.191268	0.293301

Danceability Normalized (à esquerda):

A distribuição apresenta uma assimetria leve, com a maior parte dos valores concentrados em torno de 0 e ligeiramente inclinada para valores negativos. Isso sugere que, embora a maioria das músicas tenha valores medianos de Danceability, existem algumas com baixa propensão à dança (valores mais negativos) e menos com alta propensão (valores mais positivos).

Esse padrão é consistente com estudos como Bergeron & Wild (2016), que destacam que a propensão à dança varia amplamente dependendo do gênero musical, com faixas acústicas ou reflexivas tendendo a pontuar mais baixo nessa métrica.

Popularity Normalized (à direita):

A distribuição é mais simétrica, com um formato próximo ao de uma curva normal. O pico da distribuição está próximo de 0, indicando que a maioria das músicas tem uma popularidade média em relação ao dataset.


Poucas músicas estão nos extremos (popularidade muito baixa ou muito alta), como representado pelas caudas da distribuição.

Isso reflete a diversidade do público e do mercado, onde algumas músicas se tornam hits excepcionais enquanto outras permanecem em nichos mais restritos. Estudos como Serrà et al. (2012) destacam que a popularidade é frequentemente influenciada por fatores externos, como promoção e presença nas mídias sociais, além das características musicais intrínsecas.

Por exemplo, no caso de Danceability, o valor 0.933687 na primeira linha significa que o dado original está aproximadamente 0.93 desvios padrão acima da média da variável. Já para Popularity, o valor -1.240963 indica que o dado original está 1.24 desvios padrão abaixo da média.

Distribuições amostrais:

Popularidade



Comportamento Geral:

A média das amostras para a variável Popularity está em torno de 70, que representa a média populacional.

Assim como em Energy, amostras menores (10) geram distribuições mais amplas, com maior dispersão.


Efeito do Tamanho da Amostra:

Amostras maiores (100, 500 e 1000) resultam em distribuições mais estreitas e bem centradas.

A estabilidade da média aumenta significativamente com o tamanho da amostra, reduzindo o risco de estimativas distorcidas.

O comportamento observado confirma que a média das amostras se aproxima da média populacional conforme o tamanho da amostra cresce, evidenciando a robustez do processo de amostragem.

Dancabilidade



Comportamento Geral:

A média das amostras para a variável Danceability está centrada em 0.65, indicando uma média populacional estável.

A dispersão é maior para amostras pequenas (10), como esperado.


Efeito do Tamanho da Amostra:

Para tamanhos maiores (100, 500 e 1000), as distribuições tornam-se muito concentradas, com uma redução significativa na variabilidade.

Isso demonstra que médias calculadas de amostras maiores fornecem estimativas mais confiáveis para Danceability.

O gráfico ilustra claramente como o aumento do tamanho da amostra leva a uma melhor precisão e menor dispersão na estimativa das médias amostrais.

Energia



Comportamento Geral:

A média das amostras para a variável Energy está centralizada em torno de 0.65, refletindo a média populacional dessa métrica.

Com amostras de tamanho pequeno (10), a distribuição das médias apresenta maior dispersão, indicando maior variabilidade nas estimativas.

Efeito do Tamanho da Amostra:

Para tamanhos maiores de amostra (100, 500 e 1000), as distribuições tornam-se mais estreitas e concentradas, reduzindo a variabilidade.

Essa redução da largura é explicada pelo erro padrão, que diminui à medida que o tamanho da amostra aumenta.


Este gráfico demonstra como amostras maiores oferecem médias mais consistentes e precisas para a variável *Energy*, confirmando o efeito do Teorema Central do Limite.

Conclusão:

Os três gráficos confirmam a aplicação prática do Teorema Central do Limite (TCL). Amostras pequenas geram estimativas mais variáveis e menos precisas, enquanto amostras maiores reduzem a dispersão e aumentam a confiabilidade das médias amostrais. As médias amostrais convergem para as respectivas médias populacionais, independentemente da variável analisada (Energy, Popularity, Danceability), reforçando a importância do uso de amostras maiores para análises estatísticas confiáveis.

A relevância prática desse fenômeno é amplamente reconhecida na literatura. De acordo com Rice (2006), a convergência das médias amostrais para a média populacional é uma das bases fundamentais da estatística inferencial, possibilitando a construção de intervalos de confiança e a realização de testes de hipóteses com maior precisão. Montgomery e Runger (2014) reforçam que amostras maiores reduzem significativamente a incerteza associada às estimativas, o que é crucial em estudos como este, onde a precisão na descrição de características musicais é essencial.

Intervalo de Confiança (popularidade)



Sample Mean: 67.62

Sample Standard Deviation: 11.36

90% Confidence Interval: 64.98 to 70.26

95% Confidence Interval: 64.47 to 70.77

Distribuição Normal:

- O gráfico representa uma **distribuição normal** baseada na amostra, com uma média de **67.62** e um desvio padrão de **11.36**.
- A curva azul descreve a densidade de probabilidade da popularidade.

Intervalos de Confiança:

- O **intervalo de confiança (IC) de 90%** é delimitado pelas linhas verdes (64.98 a 70.26). Isso significa que, se repetirmos o experimento várias vezes, 90% das médias amostrais cairiam dentro desse intervalo.
- O **intervalo de confiança (IC) de 95%** é delimitado pelas linhas vermelhas (64.47 a 70.77). Este intervalo é mais amplo porque busca incluir mais médias amostrais possíveis, aumentando a confiança.

Interpretação:

- A média amostral de **67.62** está bem centralizada, refletindo uma estimativa confiável da popularidade média da população.
- O IC de 95% sugere que há 95% de confiança de que a média populacional real de popularidade esteja entre **64.47 e 70.77**.

Importância do Intervalo de Confiança:

- Esses intervalos são úteis para avaliar a precisão das estimativas amostrais. Um intervalo estreito indica alta precisão, enquanto um intervalo amplo pode sugerir maior incerteza.
- A diferença entre o IC de 90% e o IC de 95% destaca como uma maior confiança exige um intervalo maior.

Impacto do Tamanho da Amostra nos Intervalos de Confiança:

- O tamanho da amostra desempenha um papel crucial na largura dos intervalos de confiança.
- **Amostras maiores resultam em intervalos mais estreitos**, pois reduzem a variabilidade das médias amostrais em torno da média populacional.
- Por outro lado, **amostras menores levam a intervalos mais amplos**, aumentando a incerteza em relação à média estimada.
- Assim, para a análise da popularidade, o intervalo observado também reflete o tamanho da amostra utilizada.

Conclusão:

- O gráfico evidencia que a popularidade média estimada é sólida, e os intervalos de confiança fornecem margens claras para interpretar a incerteza em torno dessa estimativa.
- A relação entre o tamanho da amostra e a precisão dos ICs destaca a importância de coletar um número adequado de observações para obter resultados mais confiáveis.

Conclusão Geral

A análise das 620 faixas do Billboard Hot 100 (2000–2023) destacou padrões importantes. Músicas mais populares têm, em geral, duração entre dois e quatro minutos, energia média de 0,6 e loudness por volta de -6 dB, características alinhadas às preferências modernas de consumo digital. A popularidade média das faixas foi de 67,62, indicando uma consistência no apelo das músicas de sucesso.

As correlações evidenciaram uma forte relação positiva entre energia e loudness, confirmando que músicas mais intensas tendem a ser mais altas. Por outro lado, a relação negativa entre acousticness e energia destacou a distinção entre músicas acústicas e eletrônicas/comerciais. Métricas como danceability mostraram correlações fracas com popularidade, reforçando que o sucesso de uma música depende de múltiplos fatores.

A análise estatística também reforçou a confiabilidade das estimativas. Intervalos de confiança estreitos demonstraram alta precisão, com 95% de probabilidade de a média populacional de popularidade estar entre 64,47 e 70,77. Além disso, o aumento do tamanho da amostra confirmou a importância de dados robustos para análises mais precisas.

Conclui-se que o sucesso musical é influenciado por uma combinação de características sonoras otimizadas para plataformas digitais e preferências contemporâneas. O estudo reforça a relevância de ferramentas estatísticas para compreender tendências de mercado e apoiar decisões na indústria musical.

Referências

- SERRÀ, J., CORRAL, A., BOGUÑÁ, M., et al. Measuring the evolution of contemporary western popular music. *Scientific Reports*, 2012.
- TARDI, M. The Loudness War: Dynamics, Compression, and Perception in Modern Music. *Journal of Music Production and Engineering*, 2020.
- BERGERON, B., WILD, J. The Role of Acousticness in Emotional Responses to Music. *Music Psychology Today*, 2016.
- SMITH, G. Streaming Platforms and the Evolution of Song Duration. *Global Music Trends Report*, 2018.
- 600 Billboard Hot 100 Tracks (with Spotify Data)
<https://www.kaggle.com/datasets/thebumpkin/600-billboard-hot-100-tracks-with-spotify-data/data>
- RICE, J. A. *Mathematical Statistics and Data Analysis*. Duxbury Press, 2006.
- MONTGOMERY, D. C., RUNGER, G. C. *Applied Statistics and Probability for Engineers*. Wiley, 2014.